

Sistema de Predicción de Abandono Estudiantil mediante Machine Learning y Recomendaciones Personalizadas

Clasificación binaria con Random Forest y generación de recomendaciones para intervención temprana

Santiago Arboleda

sarboledag@eafit.edu.co

Juan Esteban Villada

Jevilladao@eafit.edu.co

Cristian Cabezas

cdcabezasj@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT

Curso: Inteligencia Artificial . Semestre 2026-1

Entrega: 19–22 de mayo de 2026

Repositorio: <https://github.com/sarboledag/PROYECTO-FINAL>

Resumen

El abandono estudiantil representa un problema relevante para las instituciones de educación superior, ya que afecta la permanencia académica, la eficiencia institucional y el acompañamiento oportuno de los estudiantes. Este proyecto desarrolla un sistema de Inteligencia Artificial para predecir el riesgo de abandono estudiantil a partir de variables académicas, económicas y personales.

Se utilizó el dataset *Predict Students' Dropout and Academic Success*, transformando la variable objetivo original en una tarea de clasificación binaria: abandono y no abandono. Se realizó un análisis exploratorio de datos, preprocesamiento, entrenamiento de modelos y evaluación con métricas de clasificación. Se compararon tres enfoques: un baseline basado en la clase mayoritaria, una Regresión Logística y un Random Forest.

El modelo Random Forest fue seleccionado como modelo principal, alcanzando un Accuracy de 0.8847, un Recall de 0.7394, un F1-score de 0.8046 y un AUC-ROC de 0.9316. Además, se implementó una aplicación en Streamlit que permite seleccionar un estudiante, estimar su probabilidad de abandono y generar una recomendación personalizada para intervención temprana.

Palabras clave: abandono estudiantil, Machine Learning, Random Forest, clasificación binaria, Streamlit, recomendación personalizada.

1. Introducción

El abandono estudiantil es un fenómeno que afecta a muchas instituciones de educación superior. Cuando un estudiante abandona su proceso académico, no solo se ve afectado su proyecto personal y profesional, sino también la capacidad de la institución para acompañar, retener y

graduar a sus estudiantes. Por esta razón, resulta importante desarrollar herramientas que permitan identificar señales tempranas de riesgo y apoyar procesos de intervención [2].

En este proyecto se propone un sistema de Inteligencia Artificial para predecir el riesgo de abandono estudiantil a partir de información académica, económica y personal. El problema se aborda como una tarea de clasificación binaria, donde el modelo debe determinar si un estudiante pertenece a la clase *Abandona* o *No abandona*.

La **pregunta de investigación** planteada es:

“¿Puede un modelo de Machine Learning predecir el riesgo de abandono estudiantil con un F1-score superior al baseline y generar recomendaciones personalizadas que apoyen procesos de intervención temprana?”

Para responder esta pregunta se utilizó el dataset *Predict Students' Dropout and Academic Success* [1]. Se realizó un análisis exploratorio, entrenamiento de modelos de clasificación, comparación de métricas y desarrollo de una aplicación en Streamlit. El documento se organiza así: la Sección 2 describe los datos y el EDA, la Sección 3 presenta la arquitectura, la Sección 4 detalla la metodología, la Sección 5 reporta resultados y la Sección 6 discute hallazgos.

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

El dataset utilizado fue *Predict Students' Dropout and Academic Success*, el cual contiene información de estudiantes de educación superior en Portugal. La variable objetivo original incluye tres clases: *Graduate*, *Dropout* y *Enrolled*. Para este proyecto se transformó en una variable binaria *Dropout_Binary*, donde 1 representa estudiantes que

abandonaron y 0 representa graduados o aún matriculados.

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	UCI Machine Learning Repository
Registros (N)	4 424 estudiantes
Features (p)	36 variables académicas, económicas y personales
Variable objetivo	Dropout_Binary: 0 = No abandona, 1 = Abandona
Distribución	67.88 % No abandona / 32.12 % Abandona
Valores nulos	Ninguno

Después de la transformación, se obtuvo una distribución de 3 003 estudiantes en la clase *No abandona* y 1 421 en la clase *Abandona*.

2.2. Hallazgos del análisis exploratorio

El análisis exploratorio mostró que las variables académicas son las más relacionadas con el abandono estudiantil. Las variables asociadas al número de unidades curriculares aprobadas y a las calificaciones promedio del primero y segundo semestre presentaron diferencias importantes entre ambas clases.

- **Variables académicas:** el promedio de unidades aprobadas en el 2.º semestre fue 5.61 para quienes no abandonan y 1.94 para quienes abandonan. La nota promedio del 2.º semestre fue 12.27 vs. 5.89, respectivamente.
- **Variables económicas:** los estudiantes con matrícula al día y sin deudas presentaron menor probabilidad de abandono.
- **Edad de ingreso:** estudiantes que ingresan con mayor edad mostraron mayor riesgo, posiblemente por responsabilidades laborales o familiares.
- **Sin valores nulos:** no se requirió ninguna estrategia de imputación.




Figura 1: Distribución de la variable objetivo y variables más correlacionadas con el abandono estudiantil.

3. Arquitectura del Sistema

El sistema está compuesto por tres capas que operan en secuencia: (1) pipeline de ML para predicción del riesgo de abandono, (2) módulo de recomendación personalizada con estructura de prompt LLM, y (3) aplicación web Streamlit para interacción del usuario final (orientadores y coordinadores académicos).




Figura 2: Arquitectura general del sistema. El dataset alimenta el pipeline ML; la predicción activa el módulo de recomendación; la app Streamlit expone el sistema al usuario.

3.1. Componentes principales

Preprocesamiento. Se creó la variable `Dropout_Binary` a partir de la variable original multiclase. El dataset no requirió imputación de valores nulos. División: 80 % entrenamiento / 20 % prueba con `random_state=42`.

Modelo de ML. Se evaluaron tres modelos: Baseline (clase mayoritaria), Regresión Logística (con `StandardScaler` y `max_iter=1000`) y Random Forest (300 árboles, `class_weight=balanced`, `random_state=42`). Random Forest fue seleccionado como modelo principal por su mayor AUC-ROC (0.9316) y su capacidad de manejar el desbalance de clases.

Componente LLM. El módulo de recomendación extrae las variables clave del estudiante (notas, materias aprobadas, estado financiero, edad de ingreso) y genera una recomendación de intervención personalizada en lenguaje natural, clasificando el riesgo en tres niveles: Alto ($\geq 70\%$), Medio ($\geq 40\%$) y Bajo ($< 40\%$). El prompt está estructurado para ser compatible con LLMs externos (Groq, OpenAI) como extensión futura.

Aplicación Web (Streamlit). La interfaz `app.py` permite al usuario seleccionar un estudiante por índice, visualizar sus datos, ejecutar la predicción en tiempo real y obtener la recomendación de intervención. Consume los modelos serializados con `joblib`.

4. Metodología

4.1. Configuración experimental

Cuadro 2: Configuración de los modelos entrenados

Parámetro	Valor
Framework	scikit-learn
División datos	80 % train / 20 % test
Baseline	DummyClassifier (clase mayoritaria)
Regresión Logística	StandardScaler + LR, max_iter=1000
Random Forest	300 árboles, class_weight=balanced
Métrica principal	AUC-ROC
Hardware	Google Colab (CPU)

4.2. Estrategia de validación

Se utilizó **hold-out** fijo (80/20) dado que el dataset cuenta con más de 4000 registros y la proporción de la clase positiva (32.12 %) es suficiente para obtener representación en el conjunto de prueba. El uso de `class_weight=balanced` en Random Forest compensa el desbalance sin necesidad de oversampling explícito.

4.3. Experimentos realizados

1. **Baseline:** DummyClassifier que predice siempre la clase mayoritaria. AUC-ROC = 0.500, F1 = 0.000.
2. **Experimento 1 — Regresión Logística:** modelo lineal con normalización. AUC-ROC = 0.9266, F1 = 0.8054, Accuracy = 0.8859.
3. **Experimento 2 — Random Forest (mejor):** ensamble de 300 árboles con pesos balanceados. AUC-ROC = 0.9316, F1 = 0.8046, Accuracy = 0.8847.

5. Resultados

5.1. Métricas de evaluación

Cuadro 3: Comparación de modelos en el test set (N = 885)

Modelo	Acc.	F1	AUC	Recall
Baseline	0.679	0.000	0.500	0.000
Reg. Logística	0.886	0.805	0.927	0.736
Rand. Forest	0.885	0.805	0.932	0.739

El modelo Random Forest supera al baseline en 43.2 puntos de AUC-ROC y logra un F1 de 0.805 sobre la clase positiva (abandono). La Regresión Logística obtiene resultados similares (AUC = 0.927), lo que indica que las variables del dataset tienen alta separabilidad lineal. La Tabla 3 confirma que el sistema supera ampliamente el baseline propuesto.

5.2. Análisis de resultados




Figura 3: Matriz de confusión del Random Forest. 210 verdaderos positivos (abandonos detectados) y 74 falsos negativos.




Figura 4: Curva ROC de los tres modelos. Random Forest alcanza AUC = 0.932.

Las variables con mayor importancia en el Random Forest fueron: unidades curriculares aprobadas en el 2.º semestre, nota promedio del 2.º semestre, unidades aprobadas en el 1.º semestre, nota promedio del 1.º semestre y estado de pago de matrícula. Estas cinco variables explican más del 60 % de la importancia total del modelo.

5.3. Sistema de recomendación

El módulo de recomendación clasifica el riesgo y genera orientaciones accionables para cada estudiante:

```

1 Nivel de riesgo: Alto
2 Probabilidad de abandono: 87.0%
3
4 Recomendaciones:
5 - Asignar tutorías académicas de refuerzo
6 - Remitir a bienestar universitario
7   o apoyo financiero
8 - Programar revisión periódica del caso

```

Listing 1: Ejemplo de output del sistema para un estudiante de alto riesgo

6. Discusión

6.1. Interpretación de resultados

El sistema logró el objetivo planteado: Random Forest alcanza AUC-ROC = 0.932, superando el baseline (0.500) en 43 puntos y respondiendo afirmativamente la pregunta de investigación. La diferencia marginal con Regresión Logística (0.927) sugiere que el problema tiene una estructura predominantemente lineal, resultado consistente con

la literatura sobre predicción de abandono [2]. El módulo de recomendación cumple su función de traducir la predicción a lenguaje comprensible para orientadores y coordinadores académicos.

6.2. Limitaciones

- **LLM simulado:** el componente de recomendación usa reglas `if/else` con estructura de `prompt`, no un LLM real conectado a una API externa. Esto limita la riqueza y adaptabilidad de las respuestas.
- **Dominio específico:** el modelo fue entrenado con datos de universidades portuguesas; su generalización a contextos colombianos requiere re-entrenamiento con datos locales.
- **Sin RAG:** no se implementó recuperación sobre reglamentos institucionales, lo que enriquecería las recomendaciones con políticas específicas de la universidad.
- **74 falsos negativos:** estudiantes en riesgo que el modelo no detecta representan el principal punto de mejora del sistema.

6.3. Trabajo futuro

Dos extensiones concretas de alto impacto serían: (1) conectar el módulo de recomendación a un **LLM real** vía Groq o OpenAI para generar orientaciones más ricas y contextualizadas; y (2) implementar un módulo **RAG** que indexe los reglamentos académicos de EAFIT en ChromaDB, permitiendo que las recomendaciones citen artículos específicos del reglamento estudiantil.

7. Conclusiones

Este proyecto construyó un sistema funcional de predicción de abandono estudiantil que combina Machine Learning con un módulo de recomendación en lenguaje natural y una aplicación web desplegable. El modelo Random Forest alcanzó $AUC-ROC = 0.9316$ y $F1 = 0.8046$, superando ampliamente al baseline ($AUC = 0.500$) y respondiendo afirmativamente la pregunta de investigación planteada. La aplicación Streamlit permite a orientadores seleccionar estudiantes y obtener predicciones de riesgo con recomendaciones de intervención en tiempo real. El principal trabajo futuro es reemplazar el módulo de recomendación basado en reglas por un LLM real y añadir RAG sobre reglamentos institucionales para enriquecer las orientaciones generadas.

Contribuciones del equipo

Integrante	Contribución principal
Santiago Arboleda	EDA, preprocesamiento, visualizaciones
Juan Esteban Villada	Modelos ML, evaluación, métricas
Cristian Cabezas	Módulo LLM, app Streamlit, integración

Distribución de responsabilidades por integrante.

Repositorio y Demo

- **GitHub:** <https://github.com/sarboledag/PROYECTO-FINAL>
- **Video demo (≤3 min):** https://github.com/sarboledag/PROYECTO-FINAL/blob/main/video/video_demo.webm
- **Instalación:** `pip install -r requirements.txt`
- **App:** `streamlit run app.py`
- **Notebook:** `notebooks/Proyecto_Final_IA_Abandono_Estu`

Referencias

[1] Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2022). *Predict Students' Dropout and Academic Success*. UCI Machine Learning Repository. <https://doi.org/10.24432/C5MC89>

[2] Martins, M. V., Tolleo, D., Machado, J., Baptista, L. M., & Realinho, V. (2021). *Early prediction of student's performance in higher education: A case study*. Trends and Applications in Information Systems and Technologies, 166–175.

[3] Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

[4] Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.

[5] Streamlit Inc. (2019). *Streamlit: The fastest way to build data apps*. <https://streamlit.io>

A. Variables más importantes del modelo

Las 5 variables con mayor importancia según el Random Forest fueron: (1) unidades curriculares aprobadas en el 2.º semestre, (2) nota promedio del 2.º semestre, (3) unidades curriculares aprobadas en el 1.º semestre, (4) nota promedio del 1.º semestre, y (5) estado de pago de matrícula al día. Estas variables explican más del 60 % de la importancia total del modelo.

B. Estructura del repositorio

```
1 proyecto_final_ia/  
2 |-- app.py  
3 |-- README.md  
4 |-- requirements.txt  
5 |-- data/  
6 |   |-- student_dropout_procesado.csv  
7 |-- models/  
8 |   |-- modelo_random_forest.pkl  
9 |   |-- columnas_modelo.pkl  
10 |-- notebooks/  
11 |   |-- Proyecto_Final_IA_Abandono.ipynb  
12 |-- docs/  
13 |   |-- informe_final.tex  
14 |-- video/  
15 |   |-- video_demo.webm
```

Listing 2: Árbol de archivos del proyecto